멀티태스크 학습 기반 감정 인지 Transformer 대화 생성 모델

A Multi-Task Learning Based Emotion-Aware Transformer for Dialogue Generation

요 약

본 연구에서는 멀티태스크 학습 기반의 감정 인지 Transformer 대화 생성 모델을 제안한다. 기존의 Transformer 기반 모델은 문법적 정확성과 문맥 파악은 우수하나, 입력 문장에 내포된 미묘한 감정적 맥락을 파악하여 응답에 반영하는 데 한계가 있다. 이러한 문제를 해결하기 위해, 본 연구에서는 멀티태스크 학습 프레임워크 내에서 감정 분류를 보조 태스크(Auxiliary Task)로 설정하여 인코더의 표현 학습을 가이드하는 구조를 설계하였다. 구체적으로, 인코더가 대화 생성에 필요한 정보뿐만 아니라 입력 문장의 감정 상태를 예측하도록 함께 학습함으로써, 별도의 감정 입력 없이도 인코더 스스로가 감정 맥락을 내재화한 임베딩을 생성하도록 유도하였다. 제안 모델은 추론 단계에서 추가적인 감정 정보 입력이 필요치 않아 실용성이 높으며, 기존 Transformer 아키텍처에 유연하게 통합될 수 있다. 실험 결과, 제안 방법은 기존 모델 대비 응답의 자연스러움과 감정적 적절성 측면에서 향상된 성능을 보였다. 이는 감정 정보를 학습 목표로 활용하는 것만으로도 대화 모델의 공감 능력을 효과적으로 강화할 수 있음을 시사한다.

Abstract

This study proposes an emotion-aware Transformer conversation generation model based on multi-task learning. While conventional Transformer-based models excel at grammatical accuracy and contextual understanding, they face limitations in capturing and reflecting the subtle emotional nuances embedded in input sentences within their responses. To address this issue, we designed a framework where emotion classification is set as an auxiliary task within a multi-task learning setup to guide the encoder's representation learning. Specifically, by training the encoder to simultaneously predict the emotional state of the input sentence alongside the information required for response generation, we induce the encoder to autonomously generate embeddings that internalize emotional context without the need for explicit emotion labels at the input stage. The proposed model offers high practical utility as it does not require additional emotion metadata during the inference phase and can be flexibly integrated into existing Transformer architectures. Experimental results demonstrate that the proposed method outperforms baseline models in terms of both response naturalness and emotional appropriateness. These findings suggest that utilizing emotional information as a primary learning objective is an effective strategy for enhancing the empathetic capabilities of dialogue models.

Keywords : Multi-task learnning, Trasnformer, dialogue generation

Ⅰ. 서 론

최근 Transformer 기반의 언어 모델은 대화 생성 분야에서 문장의 문법적 완성도와 의미적 일관성을 비약적으로 향상시켰다. 그러나 인간의 대화는 단순한 정보 교환을 넘어 감정적 교류를 포함하기에, 모델이 입력 문장의 감정적 맥락을 정확히 이해하고 이에 대응하는 공감형 응답을 생성하는 것은 여전히 중요한 과제로 남아 있다. 기존 연구들은 감정 기반 대화 생성을 위해 입력 문장에 감정 토큰을 추가하거나 외부 감정 정보를 명시적으로 주입하는 방식을 주로 사용해 왔다. 하지만 이러한 방식은 추론 시에도 정확한 감정 레이블이 제공되어야 하거나, 감정 정보를 단순한 조건(Condition)으로만 활용하여 모델의 내부 표현(Representation) 수준에서 감정을 충분히 반영하지 못한다는 한계가 있다. 또한, 감정 정보가 입력에 직접 포함될 경우 모델이 텍스트 자체의 문맥보다는 주어진 레이블에 과도하게 의존하게 되는 부작용이 발생할 수 있다.

본 연구에서는 이러한 문제를 해결하기 위해 감정 정보를 입력으로 사용하는 대신, 학습 과정에서 인코더의 임베딩 형성을 가이드하는 '학습 목표'로 활용하는 멀티태스크 학습 기반의 대화 생성 모델을 제안한다. 제안 모델의 핵심 전략은 다음과 같다.

첫째, 대화 생성 태스크와 입력 문장의 감정 분류 태스크를 동시에 학습하는 멀티태스크 프레임워크를 구축한다. 이 과정에서 인코더는 보조 태스크인 감정 분류를 성공적으로 수행하기 위해 입력 문장의 감정적 특징을 스스로 추출하고 이를 공유 임베딩 공간에 투영하게 된다. 즉, 감정 정보를 입력 단에 명시하지 않더라도 인코더가 학습을 통해 감정 인지적 표현(Emotion-aware Representation)을 내재화하도록 유도한다.

둘째, 별도의 복잡한 구조 변경 없이 기존 Transformer 아키텍처를 유지함으로써 모델의 확장성과 효율성을 확보한다. 제안 방식은 학습 시에만 감정 데이터를 활용하고 추론 시에는 일반적인 텍스트 입력만으로도 감정이 고려된 응답을 생성할 수 있어 실무적 활용도가 높다.

실험 결과, 감정 분류를 보조 태스크로 활용하여 학습된 모델은 기존 Transformer 대비 응답의 자연스러움뿐만 아니라 감정적 일관성 측면에서도 유의미한 성능 향상을 보였다. 이는 감정 정보를 입력으로 주입하지 않더라도, 멀티태스크 학습을 통해 인코더의 표현력을 강화하는 것만으로도 공감 능력이 뛰어난 대화 시스템을 구축할 수 있음을 입증한다.

II. 관련 연구

2.1 Transformer 기반 대화 생성 모델

Vaswani et al. (2017)[1]이 제안한 Transformer 아키텍처는 어텐션(Attention) 메커니즘을 통해 문장 내 장거리 의존성(Long-range Dependency)을 효과적으로 포착함으로써 자연어 처리 분야의 패러다임을 변화시켰다. 이후 GPT(Radford et al., 2018)[2] , BERT(Devlin et al., 2019) [3]] , BART(Lewis et al., 2020) [4] 와 같은 대규모 사전 학습 모델들이 등장하며 대화 생성의 문법적 정확성과 의미적 일관성은 비약적으로 향상되었다. 그러나 이러한 모델들은 주로 텍스트의 통계적 패턴 학습에 치중되어 있어, 발화자의 감정적 상태를 깊이 있게 파악하고 이에 적절히 대응하는 데에는 여전히 한계가 존재한다. 본 연구는 이러한 표준 Transformer 구조의 장점을 유지하면서, 감정 인지 능력을 결합하여 보다 고차원적인 대화 모델을 지향한다.

2.2 공감형 대화 시스템 (Empathetic Dialogue Systems)

사용자의 감정을 이해하고 적절한 공감 반응을 생성하는 것은 인간다운 대화 시스템 구축의 핵심 요소이다. Rashkin et al. (2019) [5] 은 'EmpatheticDialogues' 데이터셋을 공개하며 공감형 대화 생성 연구의 기반을 마련하였다. 이후 연구들은 주로 외부 감정 지식베이스(Knowledge Base)를 활용하거나(Lin et al., 2019)[6], 감정 레이블을 조건부 토큰으로 주입하는 방식(Majumder et al., 2020)[7]을 제안해 왔다. 그러나 기존 연구들은 감정 정보를 단순한 입력의 일부로 취급하거나 별도의 분류기를 병렬적으로 연결하는 구조에 그치는 경우가 많았다. 이로 인해 모델 내부의 잠재 표현(Latent Representation) 공간에서 감정적 맥락이 유기적으로 통합되지 못하는 문제가 발생한다. 본 연구는 감정 정보를 모델이 직접 도출해야 할 학습 목표로 설정함으로써 이러한 분절성 문제를 해결하고자 한다.

2.3 대화 모델에서의 멀티태스크 학습 (Multi-task Learning)

멀티태스크 학습(MTL)은 관련 있는 여러 태스크를 동시에 학습함으로써 공통된 특징 표현(Shared Representation)을 강화하는 기법이다(Caruana, 1997)[8]. 대화 생성 분야에서 MTL은 주로 감정 인식, 화행 분석(Dialogue Act Classification), 지식 검색 등을 보조 태스크로 활용하여 생성 성능을 높이는 데 기여해 왔다. Liu et al. (2019)[9]은 멀티태스크 심층 신경망을 통해 자연어 이해 성능을 극대화하였으며, Lin et al. (2019)은 공감형 대화에서 감정 인식을 보조 목표로 삼아 모델의 문맥 파악 능력을 향상시켰다. 본 연구는 MTL의 하드 파라미터 공유(Hard Parameter Sharing) 방식을 채택하여, 인코더가 대화 생성에 필요한 의미 정보와 감정 분류에 필요한 특징 정보를 단일 임베딩 공간에 공존시키도록 설계함으로써 효율적이고 정교한 감정 인지 표현 학습을 도모한다.

III. 본 론

본 연구에서는 입력 문장의 감정적 맥락을 내재화하여 공감형 응답을 생성하는 감정 인지형 멀티태스크 트랜스포머(Emotion-Aware Multi-task Transformer, EAM-Transformer) 모델을 제안한다. 제안 모델은 텍스트 생성이라는 주 태스크(Primary

Task)와 감정 분류라는 보조 태스크(Auxiliary Task)를 동시에 최적화함으로써, 모델의 잠재 표현 공간(Latent Space)에 감정적 특징을 효과적으로 반영하도록 설계되었다.

3.1 모델 아키텍처 (Model Architecture) 제안

제안 모델은 표준 Transformer(Vaswani et al., 2017) 구조를 기반으로 하며, 감정 정보의 정교한 처리를 위해 다음과 같은 두 가지 핵심 컴포넌트를 통합하였다.

3.1.1 감정 임베딩 레이어 (Sentiment Embedding Layer)

입력 시퀀스의 각 토큰 임베딩(E_{token}) 과 위치 임베딩(E_{pos}) 외에, 감정 범주 정보를 담은 학습 가능한 감정 임베딩(E_{sent})을 추가적으로 결합한다. 감정 레이블은 고차원의 벡터 공간으로 사영되어 각 토큰의 표현에 다음과 같이 더해진다. $E_{total} = E_{token} + E_{pos} + E_{sent}$ 이러한 구조는 모델이 생성 초기 단계부터 특정 감정 도메인(예: 일상, 이별, 사랑 등)의 맥락적 제약을 받도록 가이드하며, 디코더가 문맥에 적합한 어휘를 선택하는 데 기여한다.

3.1.2 멀티태스크 감정 분류기 (Multi-task Emotion Classifier)

인코더의 최종 출력 벡터 $H_{enc} \in \mathbb{R}^{L \times d}$중 문장의 전역적 문맥 정보를 함축하고 있는 첫 번째 토큰인 [CLS](혹은 시퀀스의 첫 번째 위치)의 출력값 $h_{cls} \in \mathbb{R}^{d}$를 추출한다. 이를 별도의 다층 퍼셉트론(MLP) 헤드에 입력하여 감정 확률 분포를 계산한다. $P_{cls} = Softmax(W_{2(\backslash sigma(}W_1 h_{cls} + b_{1)}) + b_{2)}$.

여기서 sigma는 ReLU 활성화 함수이며, 분류기 헤드는 학습 과정에서 인코더가 텍스트의 의미적 정보뿐만 아니라 감정적 특징을 압축하도록 유도하는 감독 신호(Supervisory Signal) 역할을 수행한다.

3.2 멀티태스크 학습 전략 (Multi-task Learning Strategy)

본 연구의 핵심은 감정 정보를 단순한 입력 피처로 사용하는 것을 넘어, 인코더가 **감정 인지적 표현 (Emotion-aware Representation)**을 스스로 학습하도록 유도하는 데 있다.

- 인코더 표현 학습 (Encoder Representation): 인코더는 보조 태스크인 감정 분류를 수행하기 위해 입력 텍스트 내의 감정적 키워드와 맥락적 단서들을 식별하고, 이를 특징 공간(Feature Space)에 투영하는 법을 학습한다.이 과정에서 공유 파라미터(Shared Parameters)인 인코더는 생성 태스크에도 유용한 풍부한 감정적 맥락 벡터를 형성하게 된다.
- 디코더 문맥화 (Decoder Contextualization) : 디코더는 인코더가 생성한 감정 풍부한 맥락 벡터와 주입된 감정 임베딩을 결합한다. 이를 통해 단순한 문법적 연결을 넘어, 입력문의 감정 상태에 조응(Correspondence)하거나 적절한 감정적 거리를 유지하는 고차원적인 공감 반응을 생성한다.

3.3 손실 함수 및 최적화 (Loss Function and Optimization)

모델은 생성과 분류라는 두 가지 상이한 목표를 동시에 달성하기 위해 설계된 통합 손실 함수를 통해 최적화된다. 생성 손실 타겟 답변의 각 토큰에 대한 음의 로그 가능도(Negative Log-Likelihood)를 계산한다.

$$L_{\geq n} = -\sum_{t=1}^{T} \log P(y_t | y_{<t}, X, s)$$

분류 손실 입력 문장의 실제 감정 레이블 s와 모델의 예측값 간의 Cross-Entropy 손실을 계산한다.

$$L_{cls} = -\sum_{i=1}^{K} s_i \log(P_{cls,i})$$

최종 손실 함수는 하이퍼파라미터 α를 통해 두 태스크 간의 가중치를 조절한다.

$$L_{total} = L_{\geq n} + \alpha * L_{cls}$$

학습 시에는 최적의 수렴을 위해 Warmup Steps가 포함된 AdamW 옵티마이저를 사용하였다. 이는 학습 초기 분류 태스크의 높은 오차로 인해 생성 태스크가 방해받는 것을 방지하며, 모델이 복잡한 멀티태스크 목표를 안정적으로 학습하게 한다.

3.4 추론 및 평가 (Inference and Evaluation)

추론(Inference) 단계에서는 외부의 정답 감정 레이블에 의존하지 않고, 모델의 인코더가 실시간으로 예측한 감정 결과 $\mathrm{hats} = \mathrm{argmax}_i \mathrm{P}_{\mathrm{cls,i}}$ 를 감정 임베딩 레이어의 입력으로 피드백한다.

이는 모델이 스스로 문장을 이해하고 그에 맞는 감정 모드를 설정하여 답변을 생성하는 '자기 완결적 생성'을 가능케 한다. 본 연구에서는 제안 모델의 성능 검증을 위해 다음과 같은 지표를 활용한다.

- 언어적 유사도 (Textual Similarity): 참조 문장(Reference)과의 단어 중첩도를 측정하는 BLEU-1, 2, 4 및 ROUGE-L 점수를 산출하여 생성 결과의 문법적 완성도를 평가한다.
- 감정 일관성 (Emotional Consistency): 생성된 응답이 의도된 감정 범주를 얼마나 잘 유지하고 있는지 분석하기 위해 별도의 사전 학습된 감정 분류기를 통한 정확도를 측정한다.

Ⅳ. 실 험 및 결과 분석

4.1 실험 환경 설정 (Experimental Setup)

본 연구에서 제안한 멀티태스크 학습 기반의 감정 인지 Transformer 모델의 유효성을 검증하기 위해, 동일한 하이퍼파라미터 구조를 가진 기본 Transformer 모델(Baseline)과 비교 실험을 수행하였다.

모델은 4계층(4-layer) Transformer 구조를 기반으로 하며, 상세 설정은 다음과 같다. 은닉층 차원(d_{model})은 512, 어텐션 헤드 수(n_{head})는 8, 피드포워드 네트워크 차원(d_{ff})은 2,048로 설정하였다. 모델의 일반화 성능 향상을 위해 0.3의 드롭아웃(Dropout) 비율을 적용하였으며, 위치 정보 반영을 위해 200 길이의 포지셔널 인코딩(Positional Encoding)을 사용하였다. 또한, 인코더-디코더 간 임베딩 공유 및 출력 레이어와의 가중치 타이잉(Weight Tying)을 적용하여 학습 효율을 높였다. 최적화 과정에서는 60 스텝의 웜업(Warm-up) 구간을 포함한 학습률 스케줄러(Learning Rate Scheduler)를 사용하여 안정적인 수렴을 도모하였다.

4.2 데이터 전처리 (Data Preprocessing)

모델 학습에 앞서 입력 데이터의 노이즈를 제거하고 품질을 확보하기 위해 단계별 전처리를 수행하였다. 먼저 영문 데이터는 모두 소문자로 변환하였으며, 한글, 영문, 숫자 및 필수 문장 부호를 제외한 특수문자는 제거하였다. 이후 형태소 분석기를 활용하여 토큰화를 수행하였으며, 데이터셋 내 토큰 길이 분포 분석을 통해 시퀀스의 최대 길이를 32로 설정하였다. 이러한 정제 과정은 모델이 불필요한 노이즈에 간섭받지 않고 핵심적인 의미 구조와 감정 정보를 학습할 수 있도록 돕는다.

4.3 데이터 증강 (Data Augmentation)

데이터 부족 문제를 해결하고 모델의 견고성(Robustness)을 확보하기 위해, 단어 임베딩 기반의 어휘 치환(Lexical Substitution) 기법을 활용한 데이터 증강을 실시하였다. 각 문장에서 무작위로 선택된 단어를 임베딩 공간상에서 유사도가 가장 높은 단어로 대체함으로써, 문맥적 의미를 유지하면서도 다양한 표현을 생성하였다. 증강된 데이터셋은 다음 세 가지 조합으로 구성되었다:

- 증강된 질문 + 원본 답변
- 원본 질문 + 증강된 답변
- 원본 질문 + 원본 답변 (기존 데이터)

이 과정을 통해 전체 학습 데이터셋을 약 3배 확장하였으며, 최종적으로 23,043개의 정제된 데이터를 확보하였다. 이는 모델이 다양한 어휘적 변이(Lexical Variation)에 대해 강건한 표현력을 학습하는 기반이 되었다.

4.4 정량적 결과 (Quantitative Results)

제안 모델과 기존 Transformer 모델의 성능을 비교 분석한 결과는 표 1과 같다. 성능 지표로는 생성 품질 측정을 위해 BLEU와 ROUGE-1을 사용하였다.

모델	BLEU	ROUGE-1	ROUGE-L
Baseline Transformer	0.47	9.35	8.88
Ours	**0.68**	**10.31**	-

표 1. 모델 성능 비교 결과

실험 결과, 제안 모델은 BLEU 점수에서 기존 모델 대비 약 44.6% 향상된 0.68을 기록하였으며, ROUGE-1 역시 10.31로 개선된 성능을 보였다. 이는 감정 정보를 반영한 멀티태스크 학습과 데이터 증강 기법의 결합이 자연스러운 문장 생성 및 질의응답 품질 향상에 유의미하게 기여했음을 입증한다.

4.5 임베딩 분석 (Embedding Analysis)

감정 표현 학습이 모델 내부 표현에 미치는 영향을 분석하기 위해, 학습된 임베딩 공간을 t-SNE(t-Distributed Stochastic Neighbor Embedding)를 통해 시각화하였다.

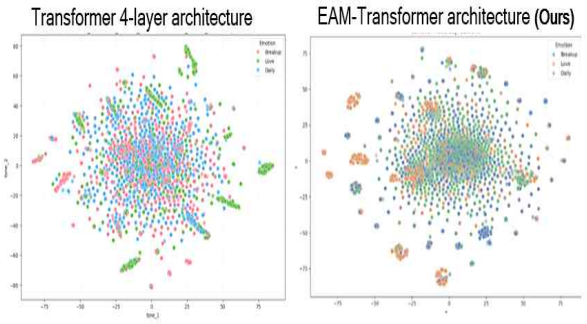

그림 1. t-SNE를 이용한 감정 임베딩 시각화 비교

시각화 결과, 기존 Transformer 모델은 서로 다른 감정 레이블이 경계 없이 혼재된 분포를 보이는 반면, 제안 모델은 기존 모델 보다 감정 카테고리별로 조금더 분리된 클러스터(Cluster)를 형성하는 것을 확인하였다. 이는 모델이 단순히 텍스트의 통계적 패턴만을 학습하는 것을 넘어, 멀티태스크 학습을 통해 감정적 맥락을 내재화한 고차원적인 표현(Representation)을 보다 잘 학습했음을 확인할 수 있다.

4.6 정성적 결과 분석 (Qualitative Analysis)

본 절에서는 정량적 지표인 BLEU와 ROUGE 점수의 향상이 실제 대화의 품질에 어떠한 영향을 미쳤는지 확인하기 위해, 기존 Transformer 모델(Baseline)과 본 연구에서 제안한 모델의 추론(Inference) 결과를 비교 분석하였다.

그림 2 Baseline 모델과 제안 모델의 답변 비교

먼저, 기존의 기본 Transformer 모델은 질문의 의도를 정확히 파악하지 못하거나 문법적으로 어색한 답변을 생성하는 한계를 보였다. 예를 들어, 사용자가 "나 차일 거 같아"라는 고민을 털어놓았을 때, 기존 모델은 "나 좋아보는 사람이고 더 좋을 수도 있어요"와 같이 문맥이 맞지 않고 비문(非文)에 가까운 답변을 내놓았다. 또한 "사랑해"라는 감정 표현에 대해서도 "사랑은 더 좋은 이 있어요"와 같이 일관성이 부족한 기계적인 반응을 보였으며, "사랑이 뭘까"라는 본질적인 질문에는 "해보세요"라는 단편적인 답변만을 생성하였다. 이는 기존 모델이 단어 간의 통계적 확률에만 의존하여 답변을 생성함으로써, 대화의 맥락이나 감정적 깊이를 반영하지 못했음을 시사한다. 반면, 제안한 모델은 멀티태스크 학습을 통해 감정 정보를 내재화함으로써 기존 모델보다 훨씬 자연스럽고 공감 능력을 갖춘 답변을 생성하였다. "심심하다"라는 일상적인 문장에 대해 "저랑 같이 놀아요. 그래도 아픔이네요"와 같이 사용자와의 상호작용을 유도하는 답변을 생성하였는데, 이는 모델이 단순한 정보 전달을 넘어 대화의 상대방으로서 역할을 수행하려 시도하고 있음을 보여준다. 특히 "좋아하면 원래 더 주고 싶나?"라는 추상적인 질문에 대해 "사랑을 하는 것 같아요"라고 답변한 점은 주목할 만하다. 이는 모델이 질문 속에 내포된 '헌신'이나 '호감'의 감정을 '사랑'이라는 상위 개념으로 연결하고, 질문자의 심리 상태를 정의하여 적절한 피드백을 제공할 수 있음을 의미한다.

결과적으로 정성적 분석을 통해 확인한 제안 모델의 특징은 크게 두 가지로 요약된다. 첫째, 데이터 증강과 정교한 전처리를 통해 문장의 문법적 완성도와 자연스러움이 크게 개선되었다. 둘째, 감정 인지 기반의 임베딩 학습 덕분에 질문의 의도를 보다 입체적으로 파악하고 정서적 공감이 담긴 답변을 생성할 수 있게 되었다. 이러한 결과는 본 연구에서 제안한 멀티태스크 학습 구조와 감정 레이블 활용 방식이 실제 대화 서비스 환경에서 사용자 만족도를 높이는 데 기여할 수 있음을 입증한다.

V. 결 론

5.1 결론 (Conclusion)

본 연구에서는 멀티태스크 학습(Multi-task Learning)을 적용하여 감정 인지 능력을 갖춘 Transformer 기반의 대화 모델을 제안하고 그 성능을 검증하였다. 제안된 모델은 단순히 문장을 생성하는 것에 그치지 않고, 감정 분류 태스크를 병행함으로써 모델 내부의 임베딩 공간에 정서적 맥락을 효과적으로 내재화하였다. 또한, 데이터 부족 문제를 해결하기 위해 어휘 치환 기반의 데이터 증강 기법을 도입하여 모델의 일반화 성능과 견고성을 동시에 확보하였다.

실험 결과, 제안 모델은 정량적 평가지표인 BLEU에서 기존 Transformer 대비 약 **44.6% 향상된 0.68점**을 기록하였으며, **ROUGE-1 지표에서도 유의미한 성능**

개선을 보였다. t-SNE를 이용한 임베딩 시각화 분석에서는 감정별 클러스터가 보다 더 구분되는 것을 확인하여, 멀티태스크 학습이 감정 정보의 특징 추출에 효과적임을 입증하였다. 정성적 분석에서도 제안 모델은 기존 모델의 기계적이고 단편적인 답변에서 벗어나, 사용자의 심리 상태를 고려한 공감형 답변과 자연스러운 대화 지속 능력을 보여주었다. 결론적으로 본 연구는 감정 레이블을 활용한 멀티태스크 학습이 대화 모델의 언어 생성 품질과 정서적 지능을 동시에 높일 수 있는 유효한 방법론임을 확인하였다.

5.2 한계점 및 향후 연구 과제 (Limitations and Future Work)

본 연구의 성과에도 불구하고 다음과 같은 몇 가지 한계점이 존재하며, 이는 향후 연구를 통해 보완될 필요가 있다.

첫째, 데이터셋 규모와 다양성의 한계이다. 데이터 증강을 통해 학습 데이터 수를 확장하였으나, 여전히 대규모 언어 모델(LLM) 학습에 비하면 데이터의 절대량이 부족하다. 이로 인해 모델이 학습하지 못한 특정 도메인의 질문이나 복합적인 감정이 섞인 대화에서는 답변의 정확도가 하락할 가능성이 있다. 향후에는 더 방대하고 정교한 감정 대화 코퍼스를 확보하여 모델의 수용력을 넓혀야 한다.

둘째, 답변의 의미론적 일관성 문제이다. 정성적 분석에서 나타났듯이, 일부 답변(예: "심심하다"에 대한 "아픔이네요")에서 감정 정보가 과도하게 반영되어 문맥상 다소 추상적이거나 의미가 모호한 표현이 생성되는 경우가 발견되었다. 이는 생성 태스크와 분류 태스크 간의 가중치 조절이나 감정 정보 주입 방식의 정교화가 더 필요함을 시사한다.

셋째, 평가 지표의 국한성이다. 본 연구에서는 BLEU와 ROUGE 등 n-gram 기반의 통계적 지표를 주로 활용하였으나, 이러한 지표는 대화의 맥락적 적절성이나 감정적 공감 수준을 완벽히 측정하기 어렵다. 향후 연구에서는 인간 평가(Human Evaluation)를 병행하거나, 대화의 논리적 흐름과 정서적 만족도를 측정할 수 있는 새로운 평가지표를 도입할 계획이다.

마지막으로, 본 연구의 구조를 최신 사전학습 모델(Pre-trained Language Model)인 BERT나 GPT 계열의 구조와 결합한다면, 더욱 강력한 언어 이해 능력을 바탕으로 한 고도화된 감정 대화 시스템 구축이 가능할 것으로 기대된다.

REFERENCES

[1] Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., ... & Polosukhin, I. (2017). Attention is all you need. In Advances in Neural Information Processing Systems (NeurIPS) (pp. 5998-6008).

[2] Radford, A., Wu, J., Child, R., Luan, D., Amodei, D., & Sutskever, I. (2019). Language models are unsupervised multitask learners. OpenAI blog, 1(8), 9.

[3] Devlin, J., Chang, M. W., Lee, K., & Toutanova, K. (2019). BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. In Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (NAACL-HLT) (pp. 4171-4186).

[4] Lewis, M., Liu, Y., Goyal, N., Ghazvininejad, M., Mohamed, A., Levy, O., ... & Zettlemoyer, L. (2020). BART: Denoising Sequence-to-Sequence Pre-training for Natural Language Generation, Translation, and Comprehension. In Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics (ACL) (pp. 7871-7880).

[5] Rashkin, H., Smith, E. M., Li, M., & Boureau, Y. L. (2019). Towards Empathetic Open-domain Conversation Models: A New Benchmark and Dataset. In Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics (ACL) (pp. 5370-5381).

[6] Lin, Z., Madotto, A., Shin, J., Xu, P., & Fung, P. (2019). MoEL: Mixture of Empathetic Listeners. In Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP) (pp. 121-132).

[7] Majumder, N., Poria, S., Peng, H., Chhaya, N., Cambria, E., & Mihalcea, R. (2020). MIME: MIMicking Emotions for Empathetic Response Generation. In Proceedings of the 2020 Conference on Empirical Methods in Natural Language

Processing (EMNLP) (pp. 8968-8979).

[8] Caruana, R. (1997). Multitask learning. Machine learning, 28(1), 41-75.

[9] Liu, X., He, P., Chen, W., & Gao, J. (2019). Multi-Task Deep Neural Networks for Natural Language Understanding. In Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics (ACL) (pp. 4487-4496).